

Market Timing con Detección de Regímenes: Un Análisis Empírico de las Estrategias de Trading Adaptativo y sus Limitaciones

Francisco Encina Aballay
Universidad Técnica Federico Santa María, Chile

Abstract—Los mercados financieros alternan entre distintos regímenes, lo que ha motivado el uso de estrategias de trading adaptativo basadas en detección automática de contexto. Este trabajo evalúa si un sistema que combina Hidden Markov Models (HMM) y modelos de machine learning especializados por régimen puede superar una estrategia pasiva de buy-and-hold. Utilizando datos diarios del S&P 500 (1993–2025) y una evaluación out-of-sample en 2019–2025, los resultados muestran que la estrategia adaptativa obtuvo un retorno acumulado de -15.5%, frente al +152.3% del buy-and-hold, con un Sharpe ratio negativo. El análisis evidencia limitaciones estructurales del market timing basado en regímenes, asociadas a precisión predictiva insuficiente, sobreajuste en regímenes poco frecuentes y una desfavorable asimetría entre oportunidad y protección.

■ **LOS MERCADOS FINANCIEROS** son sistemas dinámicos no estacionarios que alternan entre distintos regímenes—alcistas, bajistas y de alta volatilidad—cada uno con propiedades estadísticas diferenciadas. Estrategias de inversión estáticas que ignoran este contexto suelen ser subóptimas, especialmente durante transiciones de régimen y eventos de crisis, lo que ha motivado el desarrollo de sistemas de trading adapta-

tivo basados en detección automática de regímenes.

Sin embargo, persisten brechas relevantes en la literatura. Muchos estudios privilegian modelos excesivamente complejos o simplificaciones poco realistas, mientras que existe escasa evidencia empírica que cuantifique el trade-off entre sofisticación metodológica y mejora efectiva en performance. En particular, no está claro si la especialización contextual mediante machine learning justifica su complejidad

frente a estrategias pasivas.

Este trabajo evalúa empíricamente si sistemas de trading adaptativo basados en Hidden Markov Models (HMM) y especialización de modelos de machine learning por régimen pueden superar estrategias pasivas. Se implementa un pipeline completo que detecta tres regímenes de mercado usando HMM entrenado en 32 años de datos del S&P 500 (1993–2025), entrena modelos XGBoost especializados por contexto y construye un sistema adaptativo evaluado mediante backtesting riguroso out-of-sample (2019–2025), incluyendo eventos extremos como la crisis COVID-19.

Contrario a la hipótesis inicial, el sistema adaptativo obtuvo un retorno acumulado de -15.5% frente a +152.3% del buy-and-hold, con Sharpe ratio negativo (-0.158 vs. 0.764). Los modelos especializados alcanzaron solo 55–56% de accuracy y no superaron al baseline genérico; el régimen de alta volatilidad presentó overfitting severo (45.7% accuracy) debido a escasez de datos. El análisis identifica tres causas estructurales compiladas: accuracy insuficiente para market timing binario, especialización contraproducente en regímenes raros y una asimetría desfavorable entre oportunidades capturadas y protección efectiva.

Más que proponer un sistema exitoso, este trabajo contribuye al demostrar rigurosamente por qué enfoques adaptativos aparentemente razonables fallan en la práctica. Los resultados respaldan la eficiencia de mercados y sugieren que futuras investigaciones deberían priorizar optimización adaptativa de portafolios, gestión dinámica de riesgo o estrategias long-short por sobre market timing binario. El resto del artículo se organiza de la siguiente forma: Sección 2 revisa trabajos relacionados, Sección 3 describe la metodología, Sección 4 presenta resultados, Sección 5 discute implicancias, Sección 6 concluye y Sección 7 explica limitaciones y futuro.

RELATED WORK

“A Hybrid Learning Approach to Detecting Regime Switches in Financial Markets” [1]

El trabajo propone un framework híbrido que combina aprendizaje no supervisado, mediante clustering, y aprendizaje supervisado, a través de modelos de clasificación, para la detección de regímenes de mercado. Para ello, utiliza PCA como técnica de reducción de dimensionalidad aplicada a 26 indicadores económicos provenientes de FRED, y luego emplea k-means para identificar los distintos regímenes. Poste-

riormente, estos regímenes son clasificados utilizando modelos como Random Forest, SVM y Gradient Boosting. Con esta estructura, los autores construyen y backtestean dos estrategias de trading para el período 2014–2020. Sus resultados muestran que este enfoque híbrido permite detectar regímenes sin la necesidad de especificar previamente el número de estados, lo que representa una ventaja importante frente a los modelos de Markov tradicionales. En este sentido, la brecha que el trabajo aborda es justamente la limitación de los modelos Markovianos, que requieren definir de antemano cuántos regímenes existen, mientras que aquí dicho número emerge automáticamente gracias al clustering.

“Regime-Switching Factor Investing with Hidden Markov Models” [2]

El estudio utiliza un modelo HMM de tres estados —alcista, bajista y neutral— para identificar regímenes de mercado en el S&P 500 y propone una estrategia de inversión que rota entre distintos modelos factoriales según el régimen detectado. Para ello, los autores realizan un backtest de factores como momentum, value, quality y low volatility durante 10,5 años (2007–2017), entrenan el HMM y posteriormente evalúan los resultados out-of-sample entre 2017 y 2020. Sus hallazgos muestran que esta estrategia adaptativa supera consistentemente a cada modelo factorial individual, tanto en retornos absolutos como en métricas ajustadas por riesgo, incluyendo el ratio de Sharpe. Además, demuestran que el desempeño de los factores es cíclico y depende fuertemente del régimen de mercado. De esta manera, el trabajo aborda la brecha de los modelos factoriales tradicionales, los cuales aplican la misma estrategia sin considerar el régimen vigente, y evidencia que adaptar los factores al régimen puede mejorar de manera significativa el rendimiento.

“RegimeFolio: A Regime Aware ML System for Sectoral Portfolio Optimization in Dynamic Markets” [3]

El trabajo presenta un framework modular compuesto por tres elementos: un clasificador basado en el VIX para la detección de regímenes, un conjunto de modelos ensemble específicos para cada régimen y sector —combinando Random Forest y Gradient Boosting— y un optimizador dinámico de media-varianza. Para segmentar el mercado, los autores definen tres regímenes de volatilidad (baja, media y alta) utilizando el VIX como indicador principal, y entrenan

modelos de machine learning independientes para cada combinación de régimen y sector, con el fin de capturar dinámicas condicionales más precisas. La evaluación se realiza sobre 34 acciones estadounidenses de gran capitalización entre 2020 y 2024, un período que abarca la pandemia de COVID-19, la inflación y la posterior recuperación. Los resultados muestran un retorno acumulado del 137%, un Sharpe de 1.17, un drawdown 12% menor respecto a los modelos de referencia y una mejora del 15–20% en la exactitud predictiva. La brecha que el estudio aborda radica en que los métodos tradicionales asumen estacionariedad; en contraste, RegimeFolio integra detección explícita de regímenes y especialización sectorial, lo que incrementa la robustez en mercados altamente dinámicos.

“Downside Risk Reduction Using Regime-Switching Signals: A Statistical Jump Model Approach” [4]

El estudio introduce los Statistical Jump Models (JM) como una alternativa más robusta que los HMM tradicionales para la identificación de regímenes de mercado. Estos modelos incorporan una penalización explícita a los saltos entre estados, lo que permite generar secuencias de régimen mucho más persistentes y estables. Con ello, los JMs superan varias limitaciones de los HMMs, incluyendo su alta sensibilidad al desbalance de clases —donde los mercados bajistas son poco frecuentes—, la escasez de datos y la especificación errónea de la función de verosimilitud. Los autores implementan además una estrategia binaria de inversión: tomar posición en SPY en períodos de baja volatilidad y mantenerse en efectivo durante regímenes de alta volatilidad. Durante el crash del COVID-19 en 2020, este enfoque permite evitar cerca de un 20% de drawdown al detectar tempranamente el régimen de crisis. Finalmente, proponen un método data-driven para seleccionar el parámetro de penalización de saltos mediante validación cruzada en series temporales. En conjunto, el trabajo aborda la brecha de los HMMs tradicionales, que suelen producir falsas alarmas debido a su baja persistencia de estados, mientras que los JMs ofrecen regímenes más estables y por tanto más útiles para la asignación de activos.

“AI-Enhanced Portfolio Management: Leveraging Machine Learning for Optimized Investment Strategies in 2024” [5]

El trabajo ofrece una revisión comprehensiva del uso de técnicas de inteligencia artificial y machine

learning aplicadas al portfolio management en 2024, explorando enfoques como reinforcement learning, NLP y análisis de sentimiento para desarrollar estrategias dinámicas y adaptativas. A lo largo del análisis, los autores enfatizan la importancia del ajuste continuo de los portafolios en función de las condiciones de mercado en tiempo real, así como las consideraciones éticas y los posibles sesgos presentes en los modelos de IA, subrayando la necesidad de mayor transparencia. También examinan la generación de alpha a través de la detección de ineficiencias del mercado mediante datos alternativos, incluyendo imágenes satelitales y sentimiento extraído de noticias. Finalmente, destacan la capacidad de aprendizaje continuo de los modelos de ML en contraste con los modelos tradicionales, que dependen de recalibraciones manuales periódicas. En conjunto, el artículo cubre la brecha existente al sintetizar el estado actual de la IA en portfolio management, identificando tendencias emergentes y líneas futuras de investigación, con un énfasis especial en la interpretabilidad y la ética.

MÉTODO

Dataset y Preprocesamiento

Se utilizaron datos históricos diarios del S&P 500 (ticker SPY) obtenidos de Yahoo Finance, abarcando el período del 11 de noviembre de 1993 al 26 de diciembre de 2025 (8,086 observaciones). Los datos incluyen precio de cierre ajustado, volumen, y precios OHLC (Open, High, Low, Close).

Se calcularon 27 features técnicos: retornos simples y logarítmicos, volatilidad rolling (5, 20, 60 días anualizada), momentum a múltiples escalas (5, 10, 20, 60 días), medias móviles simples (SMA 20, 50, 200), ratios precio/SMA, cruces de medias móviles, RSI (14 períodos), indicadores de volumen, y features rezagados (lags 1, 2, 3, 5). El target binario se definió como $y_t = 1[r_{t+1} > 0]$ donde r_{t+1} es el retorno del día siguiente.

Los datos se dividieron temporalmente en entrenamiento (80%, 1993-2019, 6,460 días) y test (20%, 2019-2025, 1,616 días) sin shuffling para respetar la estructura temporal. Todos los features se normalizaron mediante StandardScaler ajustado únicamente en el conjunto de entrenamiento.

Detección de Regímenes con HMM

Se implementó un Hidden Markov Model con distribuciones Gaussianas (GaussianHMM

de `hmmlearn`) configurado con $K = 3$ estados ocultos, matriz de covarianza completa (`covariance_type='full'`), y 100 iteraciones máximas. Los features de entrada fueron retornos diarios, volatilidad rolling 20 días, y momentum 20 días, normalizados con `StandardScaler`.

El algoritmo Baum-Welch (Expectation-Maximization) estima iterativamente: (1) matriz de transición $A_{ij} = P(s_{t+1} = j | s_t = i)$, (2) distribución inicial $\pi_i = P(s_1 = i)$, y (3) parámetros de emisión $\mathcal{N}(\mu_k, \Sigma_k)$ para cada régimen k . La secuencia de estados más probable se decodifica mediante el algoritmo de Viterbi: $s^* = \arg \max_s P(s|x, \lambda)$.

Los regímenes se caracterizaron post-hoc analizando estadísticas promedio (retornos, volatilidad, momentum) de observaciones asignadas a cada estado, permitiendo asignar interpretaciones semánticas: Bull Market (retornos altos, baja volatilidad), Consolidation (retornos moderados, volatilidad media), y High Volatility (retornos cercanos a cero, volatilidad extrema).

Modelos de Machine Learning

Baseline Genérico: Se entrenó un modelo XGBoost (`XGBClassifier`) usando todos los datos de entrenamiento sin considerar régimen. Configuración: 50 árboles (`n_estimators=50`), profundidad máxima 3 (`max_depth=3`), learning rate 0.05, subsample 0.8, colsample_bytree 0.8, gamma 1, min_child_weight 5. Esta regularización agresiva se aplicó para mitigar overfitting observado en experimentos preliminares.

Modelos Especializados por Régimen: Para cada régimen $k \in \{\text{Bull Market, Consolidation, High Volatility}\}$, se entrenó un XGBoost independiente utilizando únicamente observaciones del conjunto de entrenamiento clasificadas como régimen k por el HMM. Cada modelo usa los mismos 27 features e hiperparámetros que el baseline, pero aprende patrones específicos del contexto.

Sistema Adaptativo: En tiempo de test, para cada observación t : (1) el HMM predice régimen actual $\hat{s}_t$, (2) se selecciona el modelo especializado correspondiente $M_{\hat{s}_t}$, (3) se genera predicción $\hat{y}_t = M_{\hat{s}_t}(x_t)$ donde x_t son los features del día t . Este enfoque modular permite que cada modelo se especialice en su contexto sin interferencia.

Estrategias de Trading

Se implementaron cuatro estrategias evaluadas en el período out-of-sample:

- **Buy & Hold:** Posición long constante (100% capital invertido). Retorno: $R_{BH} = \prod_{t=1}^T (1 + r_t) - 1$.
- **Baseline ML:** Señal binaria $signal_t \in \{0, 1\}$ del modelo genérico. Posición: 100% si $\hat{y}_t = 1$ (predice subida), 0% (cash) si $\hat{y}_t = 0$. Retorno estrategia: $R_{ML} = \prod_{t=1}^T (1 + signal_t \cdot r_t) - 1$.
- **Adaptive Strategy:** Idéntica a Baseline ML pero usando predicciones $\hat{y}_t$ del sistema adaptativo que selecciona modelo según régimen.
- **Regime-Aware Strategy:** Ajusta exposición según régimen y confianza. Posición w_t determinada por reglas: en Bull Market con $P(\hat{y}_t = 1) > 0.6$ usar $w_t = 1.2$ (leverage moderado), en Consolidation con alta confianza $w_t = 1.0$, en High Volatility reducir a $w_t = 0.5$ o $w_t = 0$ si predice baja. Retorno: $R_{RA} = \prod_{t=1}^T (1 + w_t \cdot r_t) - 1$.

Métricas de Evaluación

Modelos ML: Accuracy, precision, recall, F1-score en test set. Gap train-test como proxy de overfitting.

Estrategias de trading: Retorno total R , retorno anualizado $R_{\text{anual}} = (1 + R)^{252/T} - 1$, volatilidad anualizada $\sigma = \text{std}(r_t) \cdot \sqrt{252}$, Sharpe ratio $SR = R_{\text{anual}}/\sigma$, máximo drawdown $MDD = \min_t \frac{V_t - \max_{s \leq t} V_s}{\max_{s \leq t} V_s}$ donde V_t es valor del portafolio, Calmar ratio $CR = R_{\text{anual}}/|MDD|$, y win rate (porcentaje días con retorno positivo).

RESULTADOS

Detección de Regímenes

El modelo Hidden Markov con 3 estados fue entrenado utilizando 8,086 observaciones diarias del S&P 500 (período 1993-2025), empleando como features los retornos diarios, volatilidad rolling de 20 días y momentum de 20 días. El algoritmo convergió exitosamente, identificando tres regímenes distintos de mercado que fueron caracterizados según sus propiedades estadísticas.

La Figura 1 muestra la clasificación temporal de regímenes detectados sobre el precio del S&P 500. El análisis de las características promedio por régimen permitió asignar las siguientes interpretaciones:

- **Bull Market (Régimen 0):** Caracterizado por retornos diarios promedio de +0.09% (22.5%




FIGURE 1. A continuación se muestran 2 gráficos contenidos que muestran las variaciones del precio sobre SPY y la volatilidad durante el periodo que comprende desde 1993 hasta hoy. Adicionalmente, se muestra con colores los 3 regímenes detectados: Bull, Bear, High Volatility.

anualizado), volatilidad baja de 9.0%, y momentum positivo fuerte (+2.54%). Este régimen representó el 40.4% de las observaciones totales (3,269 días), capturando los períodos alcistas sostenidos del mercado con baja incertidumbre.

- **Bear Market (Régimen 1):** Exhibió retornos diarios promedio de +0.02% (6.0% anualizado), volatilidad moderada de 16.0%, y momentum débil (+0.44%). Comprendió el 40.6% de los datos (3,280 días). A pesar del nombre, este régimen no representa caídas severas sino períodos de bajo crecimiento con volatilidad elevada, correspondiendo a mercados laterales o correcciones moderadas.
- **High Volatility (Régimen 2):** Distinguido por volatilidad excepcional (media 31.0%, máximo 95.9%), retornos cercanos a cero (+0.01%, 2.3% anualizado), y momentum negativo (-1.54%). Fue el régimen menos frecuente con 19.0% de las observaciones (1,537 días). Este régimen captura crisis financieras, crashes de mercado, y períodos de pánico donde la incertidumbre domina. Los retornos extremos observados (min -10.94%, max +14.52%) confirman su naturaleza de alta volatilidad bidirec-

cional.

La matriz de transición **2** revela que los regímenes exhiben persistencia, con probabilidades de permanecer en el mismo estado entre 0.97-0.98. Las transiciones más probables ocurren desde Bull Market hacia Bear Market (0.02) y viceversa.




FIGURE 2. Matriz de Transición entre Regímenes

La validación cualitativa confirma que el modelo detectó correctamente eventos históricos conocidos: la crisis financiera de 2008-2009 (volatilidad alcanzó

95.9%), el flash crash de 2015, la corrección de diciembre 2018, y el crash por COVID-19 en marzo 2020 fueron clasificados como High Volatility, mientras que los períodos alcistas de 1995-1999, 2003-2007, 2013-2019, y 2020-2021 se identificaron como Bull Market.




FIGURE 3. Duración Promedio por Régimen

La distribución de duraciones 3 muestra que Bull Markets tienden a ser más persistentes (duración media 46 días) que episodios de High Volatility (duración media 44 días), coherente con la literatura financiera que documenta que crashes son breves pero intensos, mientras que rallies alcistas se desarrollan gradualmente.

Accuracy de Modelos

Se entrenaron cuatro configuraciones de modelos: (1) un baseline XGBoost genérico sin considerar régimen, (2) tres modelos XGBoost especializados por régimen, (3) un sistema adaptativo que selecciona dinámicamente el modelo según el régimen detectado, y (4) una estrategia regime-aware con ajuste de exposición por confianza.

Debido al severo overfitting observado en experimentos preliminares (95% accuracy en entrenamiento vs 53% en test), se aplicó regularización agresiva: max_depth=3, subsample=0.8, colsample_bytree=0.8, gamma=1, learning_rate=0.05. Esta configuración redujo el gap train-test a niveles aceptables (10-15%).

TABLE 1. Modelos en distintos escenarios de mercado

Modelo	Acc Train	Acc Test	Samples
Baseline	57.9%	56.0%	1,616
Bull Market	62.9%	55.7%	596
Bear Market	64.8%	56.0%	720
High Volatility	71.3%	45.7%	300

Los resultados de la tabla 1 muestran que el modelo baseline alcanzó 56.0% de accuracy en el conjunto de test (2019-2025), superando marginalmente el desempeño aleatorio del 50%. Los modelos especial-

izados no lograron mejorar sobre el baseline, con accuracies de 55.7% (Bull Market) y 56.0% (Bear Market). Particularmente preocupante es el desempeño en High Volatility, donde el modelo especializado alcanzó solo 45.7% accuracy—significativamente inferior al azar. Esto se atribuye al menor tamaño de muestra de este régimen (1,237 entrenamiento, 300 test), resultando en mayor overfitting evidenciado por el gap train-test de 25.6%.




FIGURE 4. Comparación baseline vs especializados por régimen




FIGURE 5. Features importantes por régimen

El análisis de feature importance 5 revela que diferentes features dominan en cada régimen: momentum prevalece en Bull Markets, mientras que volatilidad es crítica en High Volatility, validando parcialmente la hipótesis de especialización. Sin embargo, esta diferenciación no se tradujo en mejor capacidad predictiva.

Performance de Trading

Se compararon cuatro estrategias durante el período out-of-sample (julio 2019 - diciembre 2025, 1,616 días de trading):

- *Buy & Hold*: Inversión pasiva manteniendo posición 100% en SPY.
- *Baseline ML*: Estrategia long/cash usando predicciones del modelo genérico.
- *Adaptive Strategy*: Sistema que selecciona dinámicamente el modelo especializado según régimen detectado.
- *Regime-Aware Strategy*: Ajusta exposición por régimen y nivel de confianza.

TABLE 2. Comparación de estrategias: métricas de performance

Strategy	Total Return	Annual Return	Annual Volatility	Sharpe	Max Drawdown	Win Rate
Buy & Hold	152.29%	15.52%	20.32%	0.764	-33.72%	55.45%
Baseline ML	50.27%	6.56%	18.91%	0.347	-29.94%	48.82%
Adaptive Strategy	-15.52%	-2.60%	16.41%	-0.158	-38.72%	39.23%
Regime-Aware Strategy	-38.04%	-7.19%	7.85%	-0.916	-42.61%	18.87%




FIGURE 6. Rendimiento de las 4 estrategias: Buy & Hold(Gris), Baseline ML(Naranja), Adaptive Strategy(azul) y Regime-Aware Strategy(Verde)

Los resultados de la tabla 2 revelan que ninguna estrategia basada en machine learning superó al buy-and-hold pasivo. La estrategia buy-and-hold generó un retorno total de 152.29% (15.52% anualizado) con un Sharpe ratio de 0.764, estableciendo un benchmark robusto.

Contrario a la hipótesis 6, el sistema adaptativo generó pérdidas acumuladas de -15.52%, significativamente inferior tanto al buy-and-hold como al baseline ML (+50.27%). La estrategia regime-aware con ajuste de exposición empeoró aún más los resultados (-38.04%), demostrando que mayor sofisticación no garantiza mejor desempeño.

El análisis de drawdown 7 revela que las estrategias ML, paradójicamente diseñadas para gestión de riesgo, experimentaron drawdowns mayores que el buy-and-hold: -38.72% (Adaptive) y -42.61% (Regime-Aware) versus -33.72% (Buy & Hold). Estos drawdowns severos ocurrieron durante el rally post-COVID (2020-2021), cuando las estrategias permanecieron conservadoramente en cash mientras el mercado subía agresivamente.




FIGURE 7. Drawdowns de las 4 estrategias

DISCUSIÓN

Los resultados obtenidos contradicen la hipótesis inicial de que la especialización por régimen mejoraría el desempeño de estrategias de trading algorítmico. Esta sección analiza las causas fundamentales del fracaso y sus implicaciones para investigación futura.

Causas del Fracaso del Sistema Adaptativo

Limitaciones de Accuracy para Market Timing. Aunque el sistema alcanzó un 56.6% de accuracy—ligeramente superior al azar—este nivel resulta

insuficiente para estrategias binarias de market timing. El modelo capturó solo 12 de los 20 mejores días y evitó 8 de los 20 peores, con un ratio captura/protección de 0.63, evidenciando que errores en momentos críticos anulan cualquier ventaja estadística. La literatura sugiere que se requieren accuracies superiores al 65–70% para una implementación exitosa, umbral que incluso inversores institucionales raramente superan (Schwert, 2003).

Especialización y Escasez de Datos. Los modelos especializados no superaron al baseline genérico. En el régimen de alta volatilidad (1,537 observaciones), el accuracy cayó a 45.7%, con un gap train-test de 25.6%, indicando overfitting severo. Esto sugiere que la especialización solo es efectiva con volúmenes de datos suficientes; bajo este umbral, la pérdida de generalización domina cualquier ganancia teórica.

Efecto del Período de Evaluación. El out-of-sample (2019–2025) incluyó eventos extremos como el rally post-COVID, donde permanecer en cash implicó altos costos de oportunidad. Dado que los retornos están fuertemente concentrados en pocos días, fallar en ellos deteriora severamente el desempeño acumulado, ilustrando el *timing luck problem* (Bloomfield et al., 1977).

CONCLUSION

Este trabajo evaluó si sistemas de trading adaptativo basados en detección automática de regímenes mediante Hidden Markov Models y especialización contextual de modelos de Machine Learning pueden superar estrategias pasivas. Los resultados son claros: el sistema adaptativo obtuvo -15.5% de retorno frente a +152% del buy-and-hold en 2019–2025, con un Sharpe ratio negativo (-0.158 vs. 0.764).

La principal contribución no es un sistema rentable, sino la identificación rigurosa de las causas de su fracaso. Se evidencian tres barreras estructurales: (1) accuracy insuficiente (56%) para market timing binario, (2) overfitting en regímenes poco frecuentes por escasez de datos, y (3) asimetría entre oportunidades capturadas y protección efectiva.

Estos hallazgos respaldan la eficiencia semi-fuerte del mercado y muestran que mayor sofisticación técnica no garantiza generación de alpha si los supuestos subyacentes son débiles. En consecuencia, estrategias alternativas—optimización adaptativa de portafolios, gestión dinámica del riesgo o enfoques long-short—parecen más prometedoras que el market

timing binario.

En conjunto, el estudio aporta evidencia sobre qué aproximaciones no funcionan en la práctica y refuerza que, para la mayoría de los inversores, estrategias pasivas diversificadas superan consistentemente a sistemas activos, incluso cuando emplean técnicas algorítmicas avanzadas.

LIMITACIONES

Limitaciones del Estudio

Datos limitados en regímenes raros. El régimen High Volatility representó solo el 19% de las observaciones (1,537 muestras), restringiendo la capacidad de modelar crisis financieras y favoreciendo overfitting. Series históricas más largas podrían capturar más ciclos, aunque a costa de menor relevancia estructural.

Simplificación estratégica. La lógica binaria long/cash no refleja prácticas reales de gestión de portafolios con ajustes graduales de exposición, lo que pudo amplificar pérdidas y costos de oportunidad.

Costos de transacción ignorados. La omisión de comisiones, slippage e impuestos sesga los resultados a favor de estrategias activas; su inclusión habría deteriorado aún más el desempeño observado.

Periodo con eventos extremos. El test 2019–2025 incluye shocks excepcionales (COVID-19 y rally posterior), lo que desafía la robustez del sistema y limita la generalización a contextos más estables.

Activo único. El enfoque exclusivo en el S&P 500 restringe la validez externa de las conclusiones a otros mercados o clases de activos.

Direcciones para Investigación Futura

Futuras investigaciones deberían priorizar **optimización adaptativa de portafolios y gestión dinámica del riesgo** en lugar de market timing binario, utilizando detección de régimen para ajustar exposiciones, tamaños de posición y coberturas. Asimismo, enfoques **long-short**, técnicas de **transfer learning** entre regímenes, **ensembles** con modelos baseline y especializados, e incorporación de **features fundamentales, macroeconómicas y de sentiment** podrían mejorar la relación riesgo-retorno.

Finalmente, validar la metodología en otros activos (mercados emergentes, bonos, commodities o criptomonedas) y realizar análisis sistemáticos de sensibilidad permitiría evaluar la robustez y generalidad de los resultados. No obstante, incluso con estas extensiones, superar consistentemente estrategias pasivas en merca-

dos eficientes seguirá siendo un desafío estructural.

■ REFERENCES

1. Peter Akiyamen, Yi Zhou Tang, and Hussien Hussien. A hybrid learning approach to detecting regime switches in financial markets. 2021.
2. Matthew Wang, Yi-Hong Lin, and Ilya Mikhel-son. Regime-switching factor investing with hidden markov models. 2020.
3. Yiyao Zhang et al. Regimefolio: A regime aware ml system for sectoral portfolio optimization in dynamic markets. 2024.
4. Yizhan Shu, Chenyu Yu, and John M. Mulvey. Downside risk reduction using regime-switching signals: A statistical jump model approach. 2024.
5. Sharda Kumari and L.N. Mishra. Ai-enhanced portfolio management: Leveraging machine learning for optimized investment strategies in 2024. 2024.
6. [Código Fuente de la Investigación](#)